Datos del estudiante

Nombre y apellidos Abel Meneses Yaranga

Fecha de entrega 18/10/2026

Actividad 1. Tratamiento de datos para la predicción de enfermedades hepáticas

Introducción

Este informe desarrolla las dos primeras etapas del proyecto: la descripción del conjunto de datos y su tratamiento previo al modelado. El archivo act_liver_disease.csv procede del estudio de Straw y Wu (2022) sobre sesgo por sexo en la predicción de enfermedad hepática y, a su vez, del Indian Liver Patient Dataset (ILPD) de Ramana et al. (2011). El análisis se ejecutó en Python con pandas (McKinney, 2010), scikit-learn (Pedregosa et al., 2011), SciPy (Virtanen et al., 2020) y seaborn (Waskom, 2021); el cuaderno con el código y sus salidas se anexa (Meneses Yaranga, 2026).

Etapa 1. Descripción de la base de datos

1. Estructura del dataset

El archivo es un CSV de texto plano separado por comas, de 24,0 KB, con una fila de cabecera y 583 registros, cada uno correspondiente a un paciente, descritos por 11 variables. Es pequeño (76 KB en pandas) y se lee sin parámetros especiales, pero no tiene identificador de paciente, de modo que un duplicado no puede distinguirse de dos pacientes distintos. Diez columnas son numéricas (cinco enteras: Age, Alkphos, Sgpt, Sgot y Selector; cinco decimales: TB, DB, TP, ALB y A/G Ratio) y Gender es texto con dos valores, Male y Female.

Las variables responden a un panel hepático habitual. Age es la edad en años (de 4 a 90, mediana 45). TB y DB son la bilirrubina total y directa en mg/dL; Alkphos la

© MIU City University Miami

fosfatasa alcalina y Sgpt y Sgot las transaminasas ALT y AST, todas en UI/L; TP y ALB son las proteínas totales y la albúmina en g/dL, y A/G Ratio es el cociente entre albúmina y globulina. Selector es la etiqueta clínica, codificada como 1 para el paciente con enfermedad hepática y 2 para el paciente sin ella, lo que conviene recodificar a 0 y 1 antes de modelar. Selector y Gender son categóricas por naturaleza aunque se almacenen como entero y texto; las otras nueve son cuantitativas.

La composición de la muestra es desigual en las dos categóricas: 441 hombres (75,6 %) frente a 142 mujeres, y 416 pacientes enfermos (71,4 %) frente a 167 sanos. La proporción de enfermos es similar en ambos sexos (73,5 % en hombres y 64,8 % en mujeres). Dos consecuencias para el modelado: un clasificador que dijera siempre enfermo acertaría el 71,4 %, así que la exactitud no sirve para evaluarlo y la partición debe ser estratificada; y la escasez de mujeres limita lo que se aprenda sobre ellas, que es justamente la preocupación de Straw y Wu (2022).

2. Problemas de calidad del dataset

La revisión sistemática del cuaderno (sección 2) cuantificó seis problemas. El primero son los valores faltantes: solo hay 4, todos en A/G Ratio (0,69 % de las filas), en pacientes cuyos TP y ALB sí están registrados, lo que abre la puerta a reconstruir el dato en lugar de imputarlo a ciegas. El segundo son los duplicados: 13 filas son copias exactas de otra en las once columnas (26 registros implicados). Dado que el ILPD original ya los contiene y que dos pacientes con la misma analítica son posibles, se conservan, pero deben tenerse en cuenta al partir en entrenamiento y prueba, porque un duplicado repartido entre ambos conjuntos infla las métricas.

El tercero es la coherencia interna. En 3 registros la bilirrubina directa supera a la total, lo que es imposible porque la directa es una fracción de la total; al ser solo 3 filas, procede marcarlas y excluirlas de cualquier cociente DB/TB. Además, al recalcular el cociente albúmina/globulina como ALB/(TP − ALB) la diferencia con el valor registrado es pequeña en general (mediana 0,031), pero 14 registros se apartan en más de 0,1 y el peor llega a 2,3: con TP de 3,6 y ALB de 2,7 el cociente debería ser 3,0 y figura 0,7. Son errores de captura o de redondeo en pocas filas; marcarlos permite recalcular A/G Ratio desde ALB y TP, como se propone en la tarea 6.

© MIU City University Miami

En cuarto lugar, los valores extremos: Sgot alcanza 4929 UI/L, Sgpt 2000 y Alkphos 2110, y la bilirrubina total llega a 75,0 mg/dL. Son cifras compatibles con una hepatitis aguda grave y no se pueden descartar como errores, pero 3 registros de Sgot, 3 de Sgpt y 7 de Alkphos superan las 1500 UI/L y merecerían confirmación clínica. El quinto es el truncamiento de la edad, que en el ILPD se recorta a 90 años (aquí afecta a un paciente), y el sexto, el desbalance de sexo y clase ya descrito; no hay, en cambio, problemas de tipo de dato ni categorías mal escritas.

Etapa 2. Tratamiento de datos

3. Media, desviación estándar, varianza, rango e IQR de TB y DB

Tabla 1

Estadísticos descriptivos de la bilirrubina total (TB) y directa (DB), en mg/dL

Estadístico	TB	DB
Media	3,30	1,49
Mediana	1,00	0,30
Desviación estándar	6,21	2,81
Varianza	38,56	7,89
Rango (mín. a máx.)	74,60 (0,40 a 75,00)	19,60 (0,10 a 19,70)
Rango intercuartílico (Q1 a Q3)	1,80 (0,80 a 2,60)	1,10 (0,20 a 1,30)
Coeficiente de variación	188 %	189 %

Nota. n = 583. Desviación y varianza muestrales (n − 1). Elaboración propia.

Los dos indicadores de bilirrubina (Tabla 1) muestran una variabilidad enorme en términos relativos: la desviación estándar casi duplica a la media (coeficiente de variación cercano al 190 % en ambas); la varianza (38,6 en TB) no se lee directamente por estar en mg^2/dL^2. Los demás estadísticos revelan el motivo. La mediana de TB es 1,0 mientras la media es 3,30, y en DB la mediana es 0,3 frente a una media de 1,49: la media está arrastrada por una cola derecha larga. El rango intercuartílico, que describe al 50 % central de los pacientes, es de apenas 1,8 mg/dL en TB y 1,1 en DB, frente a rangos totales de 74,6 y 19,6; es decir, la mitad central de los pacientes ocupa un intervalo 40 veces más estrecho que el recorrido total en TB y 18 veces en DB.

Las implicaciones son tres. La media y la desviación estándar no son resúmenes representativos de estas variables y deben acompañarse de la mediana y el IQR. Las técnicas sensibles a la escala, como la normalización Z-Score o los modelos basados en distancias, quedarán dominadas por los pocos valores extremos. Y, sin embargo,

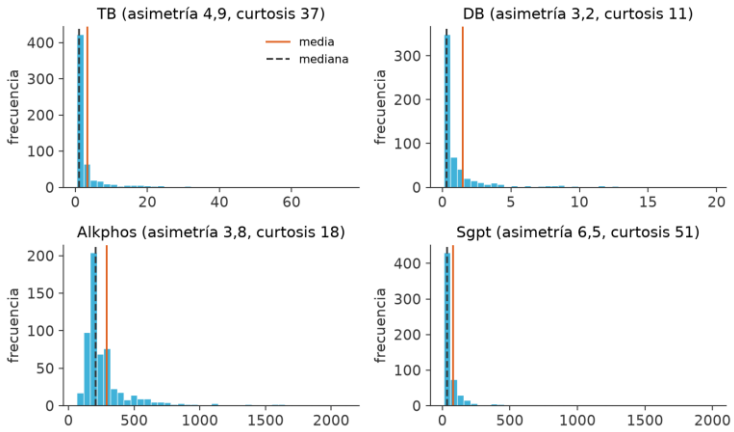
© MIU City University Miami

esa cola es informativa: la media de TB es 4,16 mg/dL en los enfermos y 1,14 en los sanos (en DB, 1,92 frente a 0,40) y la desviación estándar 7,1 frente a 1,0, de modo que casi toda la variabilidad vive en el grupo enfermo; es la señal que se quiere predecir y no debe eliminarse sin más.

4. Forma y simetría de TB, DB, Alkphos y Sgpt

Figura 1

Histogramas de TB, DB, Alkphos y Sgpt con la media (línea continua) y la mediana (discontinua)



Nota. Escala original; 40 intervalos por variable. Entre paréntesis, asimetría y curtosis de Fisher calculadas con pandas. Elaboración propia a partir de act_liver_disease.csv.

Las cuatro distribuciones son unimodales, fuertemente asimétricas a la derecha y con colas pesadas (Figura 1). Los coeficientes de asimetría son 4,9 en TB, 3,2 en DB, 3,8 en Alkphos y 6,5 en Sgpt, cuando una distribución simétrica daría cero y por encima de 1 ya se considera marcada; la curtosis, de 11 a 51, confirma que las colas concentran mucha más masa de la que tendría una normal. En las dos bilirrubinas la mitad de los pacientes se apila en el suelo de la escala (TB entre 0,4 y 1,0 mg/dL) y la media queda a la derecha del grueso de los datos; Alkphos es la única que muestra un cuerpo central reconocible en torno a 200 UI/L, y Sgpt es la más extrema, con casi todos los valores por debajo de 100 y un puñado que llega a 2000.

El cuaderno repite los histogramas con la transformación log(1 + x) (celda 4.3). La asimetría baja a valores entre 1,3 y 1,7: Alkphos y Sgpt se acercan a la lognormal (1,3 y 1,5), pero TB y DB siguen sesgadas (1,7) porque el efecto suelo no desaparece con el logaritmo. El patrón es coherente con una muestra clínica en la que la mayoría

© MIU City University Miami

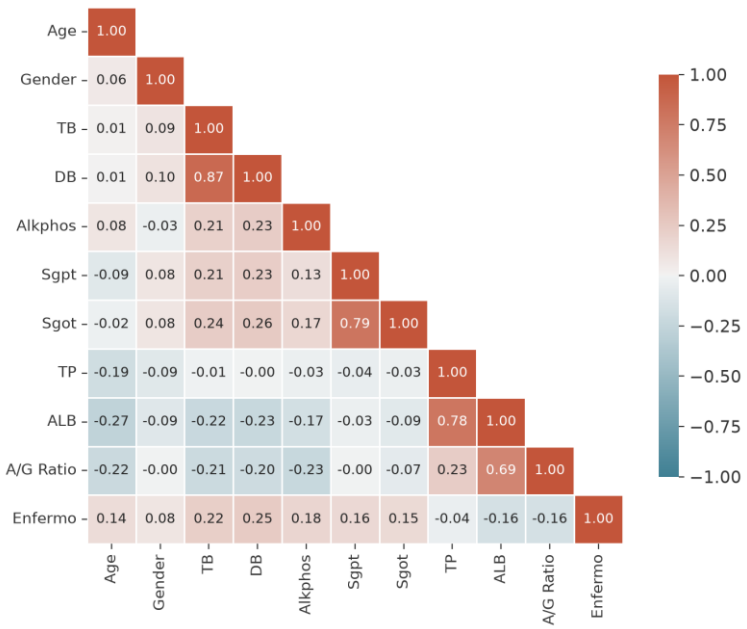
presenta valores normales y una minoría, concentrada en los enfermos, valores muy alterados. Un método que suponga normalidad (regresión logística sin transformar, análisis discriminante, Z-Score) tratará mal estas variables; log(1 + x) es el paso previo razonable y los modelos de árboles son indiferentes a la forma.

5. Relaciones entre las variables: matriz de correlación

Cuatro parejas superan un coeficiente de 0,5 y todas son significativas con $p < 0{,}001$ (Figura 2). TB y DB correlacionan 0,875 (0,959 con Spearman), lo que era de esperar porque la directa es una fracción de la total; Sgpt y Sgot, 0,792, pues ambas transaminasas se liberan con el daño hepatocelular; TP y ALB, 0,784, ya que la albúmina es el componente mayoritario de las proteínas totales; y ALB con A/G Ratio, 0,690, porque el cociente se calcula a partir de ella. Estas redundancias importan para la selección de variables: en modelos lineales o regularizados conviene conservar de cada pareja la más ligada a la clase (DB sobre TB, Sgot sobre Sgpt, ALB sobre TP) o resumirlas (la fracción DB/TB), y la terna TP, ALB y A/G Ratio contiene en realidad dos grados de libertad; los árboles toleran la colinealidad.

Figura 2

Matriz de correlación de Pearson entre las once variables, con Gender (1 = hombre) y Enfermo (1 = Selector 1) recodificadas



Nota. Triángulo inferior de la matriz; *n* = 579 pares completos para A/G Ratio y 583 en el resto. Elaboración propia a partir de act_liver_disease.csv.

© MIU City University Miami

Con la etiqueta clínica ninguna variable correlaciona con fuerza: los coeficientes de Pearson van de 0,246 (DB) y 0,220 (TB) a −0,161 (ALB) y −0,163 (A/G Ratio); todas son significativas al 5 % salvo TP (−0,035, $p = 0{,}40$), porque con $n = 583$ un $|r|$ de 0,08 (el de Gender) ya lo es: significación no implica utilidad. Con Spearman los marcadores de daño ganan peso (Sgot 0,309, TB 0,304, Sgpt 0,291, Alkphos 0,273), señal de que la relación con la enfermedad es monótona pero no lineal y de que los extremos de la escala original la ocultan (matriz completa en la celda 5.3 del cuaderno). El panorama anticipa una clasificación difícil, en la que ningún marcador aislado separa a los grupos y la ganancia vendrá de combinar variables y transformar las escalas.

6. Imputación de valores faltantes por media y moda

Solo A/G Ratio tenía faltantes y sus cuatro celdas vacías recibieron la media de la columna, 0,947. Siguiendo la guía, se calculó la media de cada columna numérica de entrada, excluida la etiqueta, y la moda de cada columna no numérica, y con pandas se rellenaron los huecos con esos valores (celda 6.1); Gender no tiene faltantes (su moda es Male). El efecto sobre la distribución es pequeño pero visible: la media se mantiene por construcción, la desviación estándar baja de 0,320 a 0,319 y la mediana sube de 0,93 a 0,947, porque en una variable asimétrica la media no es el centro.

La imputación por media es sencilla, rápida, no altera la media y sirve para cualquier algoritmo; con un 0,7 % de faltantes el daño es mínimo. Sus desventajas son conocidas: reduce la varianza y debilita las correlaciones, ignora la relación entre variables y, en una variable asimétrica, inserta un valor que no es típico (la mediana de A/G Ratio es 0,93, algo menor que la media). La imputación por moda comparte la sencillez y es la única opción directa para categorías, pero refuerza la clase mayoritaria: aquí convertiría a todo paciente de sexo desconocido en hombre. La alternativa que el propio conjunto ofrece es más precisa: como A/G Ratio se deduce de ALB y TP, los cuatro valores reconstruidos serían 1,44, 0,91, 1,08 y 1,30, bastante distintos de la media común que se les asignó. Para el modelado se recomienda esa reconstrucción determinista o, en su defecto, la mediana, y en cualquier caso ajustar el imputador solo con los datos de entrenamiento para no filtrar información de prueba.

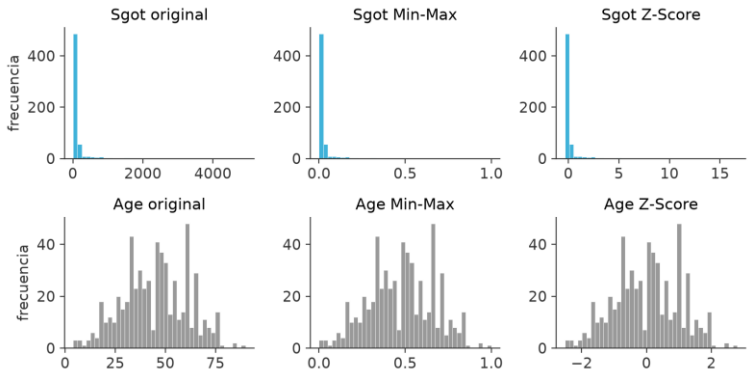
© MIU City University Miami

7. Normalización Min-Max y Z-Score

Ambas técnicas conservan la forma de cada distribución y solo difieren en cómo tratan los extremos. Sobre el conjunto ya imputado se escalaron las nueve variables numéricas de entrada con MinMaxScaler y StandardScaler de scikit-learn (celda 7.1). Min-Max resta el mínimo y divide por el recorrido, y deja cada variable en el intervalo [0, 1]; Z-Score resta la media y divide por la desviación estándar, y deja cada variable con media 0 y desviación 1. Como muestra la Figura 3, la edad, que es razonablemente simétrica, queda bien repartida en ambas escalas (media Min-Max de 0,47; Z-Score entre −2,5 y 2,8), mientras que Sgot sigue igual de concentrada.

Figura 3

Sgot (arriba) y Age (abajo) en escala original, Min-Max y Z-Score



Nota. Las transformaciones cambian la posición y la anchura, no la forma de la distribución. Elaboración propia a partir del conjunto imputado.

Ahí reside la diferencia práctica. Con Min-Max el valor máximo de Sgot (4929) se convierte en 1 y arrastra al resto: la media escalada es 0,0203 y la mediana 0,0065, es decir, la mitad de los pacientes ocupa menos del 1 % del rango disponible y el algoritmo apenas podrá distinguirlos. Con Z-Score los extremos quedan a 16,7 desviaciones en Sgot, 11,6 en TB y 10,5 en Sgpt, valores que en una normal serían imposibles y que dominarán cualquier distancia euclídea. Min-Max tiene la ventaja de un rango acotado y conocido, útil para redes neuronales y k vecinos, y la desventaja de depender solo del mínimo y el máximo y de producir valores fuera de [0, 1] si un dato nuevo los supera. Z-Score no acota el rango y también se contamina con los extremos, aunque menos, preserva la información de los atípicos y es el supuesto natural de la regresión regularizada y del análisis de componentes

© MIU City University Miami

principales; los árboles y bosques no necesitan escalado alguno, lo que aquí es una razón para preferirlos. Con colas tan largas lo adecuado es log-transformar antes de escalar, o usar un escalador robusto (mediana e IQR), ajustado solo con el conjunto de entrenamiento.

8. Valores atípicos en Sgot, TP, ALB y A/G Ratio

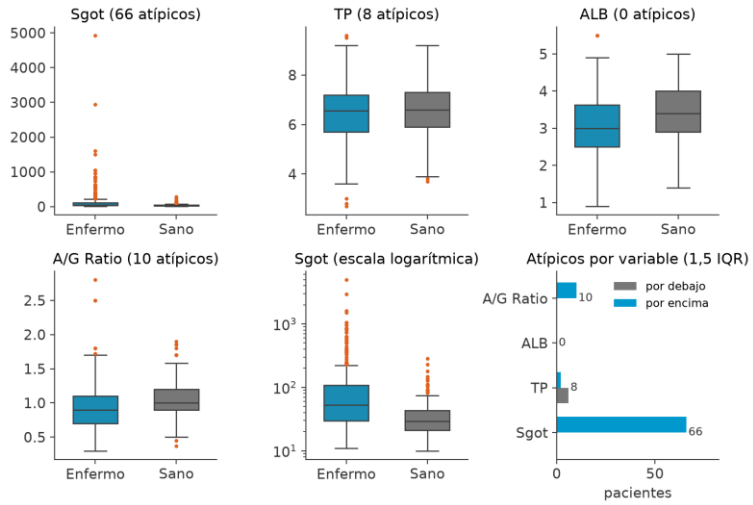
Con la regla de Tukey (1977), que considera atípico lo que cae fuera de 1,5 veces el IQR desde los cuartiles, Sgot presenta 66 atípicos (11,3 % de los pacientes), todos por encima de 180 UI/L, y 42 son extremos (más de 3 IQR). El 97 % (64 pacientes) son enfermos, frente al 71,4 % de base, de modo que borrarlos quitaría el 15 % de los enfermos y justamente los más reconocibles. TP tiene 8 atípicos, 6 por debajo de 3,7 g/dL y 2 por encima de 9,3, todos ellos enfermos. ALB no tiene ninguno (solo un 5,5 g/dL al separar por grupo), pero sus cajas por clase están desplazadas (medianas 3,0 y 3,4), mientras que las de TP son casi idénticas. A/G Ratio tiene 10 atípicos, todos por encima de 1,7, de los que 3 son extremos; 6 son enfermos y 4 sanos, es decir, proporcionalmente más frecuentes en los sanos (2,4 % frente a 1,4 %).

Los patrones son distintos en cada variable (Figura 4). En Sgot el problema no es un puñado de errores sino una cola continua: la caja de los enfermos es más alta y más ancha que la de los sanos, y en escala logarítmica se ve que los valores altos forman una secuencia sin saltos hasta 4929, salvo quizá ese último dato, 1,7 veces mayor que el siguiente (2946). En TP los atípicos son bilaterales y escasos, y los más bajos (2,7 a 3,0 g/dL) corresponden a desnutrición o insuficiencia hepática grave, no a errores. En A/G Ratio, en cambio, cinco de los diez atípicos coinciden con registros cuyo cociente no cuadra con ALB y TP (el máximo de 2,8 debería ser 0,7), de modo que aquí sí hay indicios de error de captura. En consecuencia, no se recomienda eliminar los atípicos de Sgot y TP, que llevan la señal clínica que se quiere modelar; basta transformarlos logarítmicamente o acotarlos (winsorizar) si el algoritmo lo exige. Sí conviene revisar uno a uno los 14 registros incoherentes de A/G Ratio y el máximo de Sgot antes de modelar.

© MIU City University Miami

Figura 4

Diagramas de caja de Sgot, TP, ALB y A/G Ratio por etiqueta clínica, Sgot en escala logarítmica y recuento de atípicos



Nota. Los puntos son los valores fuera de 1,5 veces el IQR de cada grupo; los recuentos corresponden a la regla aplicada a la variable completa. Elaboración propia.

Conclusiones

El conjunto de datos es pequeño (583 pacientes y 11 variables) y formalmente limpio, pero presenta cuatro problemas que condicionan su uso: 4 valores faltantes en A/G Ratio y 17 registros incoherentes (3 con DB mayor que TB y 14 con un cociente A/G que no se corresponde con ALB y TP), 13 filas duplicadas que deben controlarse al separar entrenamiento y prueba, un desbalance marcado de sexo (76 % de hombres) y de clase (71 % de enfermos), y distribuciones con colas muy largas en todos los marcadores bioquímicos.

Del análisis exploratorio se desprenden tres decisiones para el modelado. Primera, las únicas correlaciones fuertes son las que la bioquímica explica (TB con DB, Sgpt con Sgot, TP con ALB y A/G Ratio), de modo que conviene conservar una variable de cada pareja; ninguna variable por sí sola separa a enfermos de sanos. Segunda, la imputación por media y la normalización Min-Max o Z-Score funcionan, pero con colas tan largas es preferible aplicar antes una transformación logarítmica o emplear estimadores robustos. Tercera, los valores atípicos de Sgot y TP son información clínica y no deben eliminarse; solo los de A/G Ratio apuntan a errores de captura.

© MIU City University Miami

Referencias

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Meneses Yaranga, A. (2026). *Actividad 1. Tratamiento de datos para la predicción de enfermedades hepáticas* [Cuaderno Jupyter]. GitHub. https://github.com/amenesesy/actividad-cd-liver

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Ramana, B. V., Babu, M. S. P. y Venkateswarlu, N. B. (2011). A critical study of selected classification algorithms for liver disease diagnosis. *International Journal of Database Management Systems, 3*(2), 101–114. https://doi.org/10.5121/ijdms.2011.3207

Straw, I. y Wu, H. (2022). Investigating for bias in healthcare algorithms: A sex-stratified analysis of supervised machine learning models in liver disease prediction. *BMJ Health & Care Informatics, 29*(1), e100457. https://doi.org/10.1136/bmjhci-2021-100457

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software, 6*(60), 3021. https://doi.org/10.21105/joss.03021

© MIU City University Miami

Anexo. Cuaderno Jupyter

El cuaderno CD_Actividad1_Liver.ipynb, con el código y las salidas de las ocho tareas, se entrega junto con este informe y puede abrirse y ejecutarse en Google Colab con el distintivo que encabeza el repositorio (Meneses Yaranga, 2026): https://github.com/amenesesy/actividad-cd-liver

© MIU City University Miami